Plan Général du Mémoire

Conception et Déploiement d'un Système Intelligent de Traitement Automatisé des Appels d'Urgence : Modélisation, Classification et Priorisation pour la Protection Civile de Béjaïa

Variantes possibles du titre :
- Système intelligent de tri et de priorisation des appels d'urgence basé sur l'intelligence artificielle : Application à la Protection Civile de Béjaïa
- Modélisation automatique des appels d'urgence par apprentissage supervisé pour l'optimisation de la réponse opérationnelle

Introduction Générale

Les centres d'appels d'urgence constituent un maillon essentiel de la chaîne de secours, en particulier pour la Protection Civile, chargée d'intervenir rapidement face à des situations critiques telles que les incendies, les accidents de la route, les urgences médicales ou les catastrophes naturelles.

Cependant, la gestion traditionnelle des appels repose majoritairement sur des procédures manuelles, exposées à plusieurs limites : surcharge des opérateurs, erreurs d'interprétation, subjectivité dans la priorisation et retards dans la prise de décision.

L'émergence de l'intelligence artificielle (IA), et plus précisément du traitement automatique du langage naturel (TALN), offre des solutions prometteuses pour automatiser la compréhension des appels, classifier la nature des incidents et estimer leur niveau de gravité en temps réel.

Ce mémoire vise à concevoir et implémenter un système intelligent capable de :
- analyser et structurer automatiquement les appels d'urgence ;
- classifier la nature des incidents signalés ;
- estimer le niveau de criticité et de priorité ;
- assister les opérateurs dans la prise de décision ;
- proposer une architecture adaptée au contexte de la Protection Civile de Béjaïa.

Une attention particulière sera portée à la diversité linguistique des appels (arabe, tamazight, français) ainsi qu'au caractère bruité et urgent des données traitées.

Chapitre 1 : Revue Bibliographique

1.1 Gestion des appels d'urgence

Ce chapitre présente les systèmes traditionnels de gestion des appels d'urgence, leurs limites, ainsi que l'évolution vers des solutions intelligentes intégrant l'automatisation et l'aide à la décision.

1.2 Traitement Automatique du Langage Naturel (TALN)

Présentation des principales techniques utilisées :
— méthodes statistiques (TF-IDF, n-grams) ;
— représentations distribuées (Word2Vec, FastText, AraVec) ;
— modèles profonds basés sur les Transformers (BERT, AraBERT, CamemBERT, modèles multilingues).

1.3 Méthodes de classification supervisée

Étude comparative des approches classiques et avancées :
— Naive Bayes, k-NN, SVM, Random Forest ;
— réseaux neuronaux (LSTM, GRU, CNN) ;
— modèles hybrides et multitâches.

1.4 Systèmes intelligents pour la sécurité civile

Analyse des travaux récents portant sur la priorisation automatique des interventions, la gestion des ressources de secours et les applications IA dans les villes intelligentes.

Chapitre 2 : Analyse et Modélisation du Système Proposé

2.1 Description générale du système

Présentation de l'architecture globale du système intelligent de traitement des appels d'urgence.

2.2 Acquisition des données

— appels vocaux et transcription automatique (ASR) ;
— saisie textuelle assistée par les opérateurs.

2.3 Prétraitement et extraction de caractéristiques

Transformation du message textuel en représentation vectorielle :

$$X = f(\text{appel}) \to \mathbb{R}^d$$

2.4 Classification de la nature de l'incident

$$\hat{y} = C(X), \quad \hat{y} \in \{\text{Incendie, Accident, Malaise, Agression, Catastrophe, Divers}\}$$

2.5 Estimation du niveau d'urgence

$$u = g(X), \quad u \in \{1, 2, 3, 4, 5\}$$

2.6 Module de priorisation

$$P = h(\hat{y}, u, \text{localisation}, \text{ressources disponibles})$$

Chapitre 3 : Formulation Mathématique et Apprentissage

3.1 Représentation vectorielle

Pour un appel transcrit en texte T :

$$X = \text{BERT}(T) \in \mathbb{R}^{768}$$

3.2 Modèle de classification

$$\hat{y} = \text{softmax}(W_c X + b_c)$$

3.3 Modèle d'estimation de priorité

$$\hat{u} = \sigma(W_p X + b_p)$$

3.4 Fonction de perte multitâche

$$\mathcal{L} = \alpha \mathcal{L}_{class} + \beta \mathcal{L}_{priorit}$$

avec :

$$\mathcal{L}_{class} = -\sum_i y_i \log(\hat{y}_i)$$

$$\mathcal{L}_{priorit} = (u - \hat{u})^2$$

Chapitre 4 : Implémentation et Expérimentations

4.1 Description du jeu de données

Données réelles ou simulées des appels d'urgence de la Protection Civile.

4.2 Environnement de développement

Python, bibliothèques NLP, frameworks de deep learning.

4.3 Protocole expérimental

Méthodes d'évaluation, métriques utilisées (Accuracy, F1-score, Recall, Precision).

4.4 Analyse des résultats

Interprétation des performances et comparaison des modèles.

Conclusion Générale et Perspectives

Synthèse des contributions du travail, limites du système proposé et perspectives futures :

— intégration temps réel ;
— analyse audio directe ;
— extension à l'échelle nationale ;
— adaptation aux dialectes locaux.

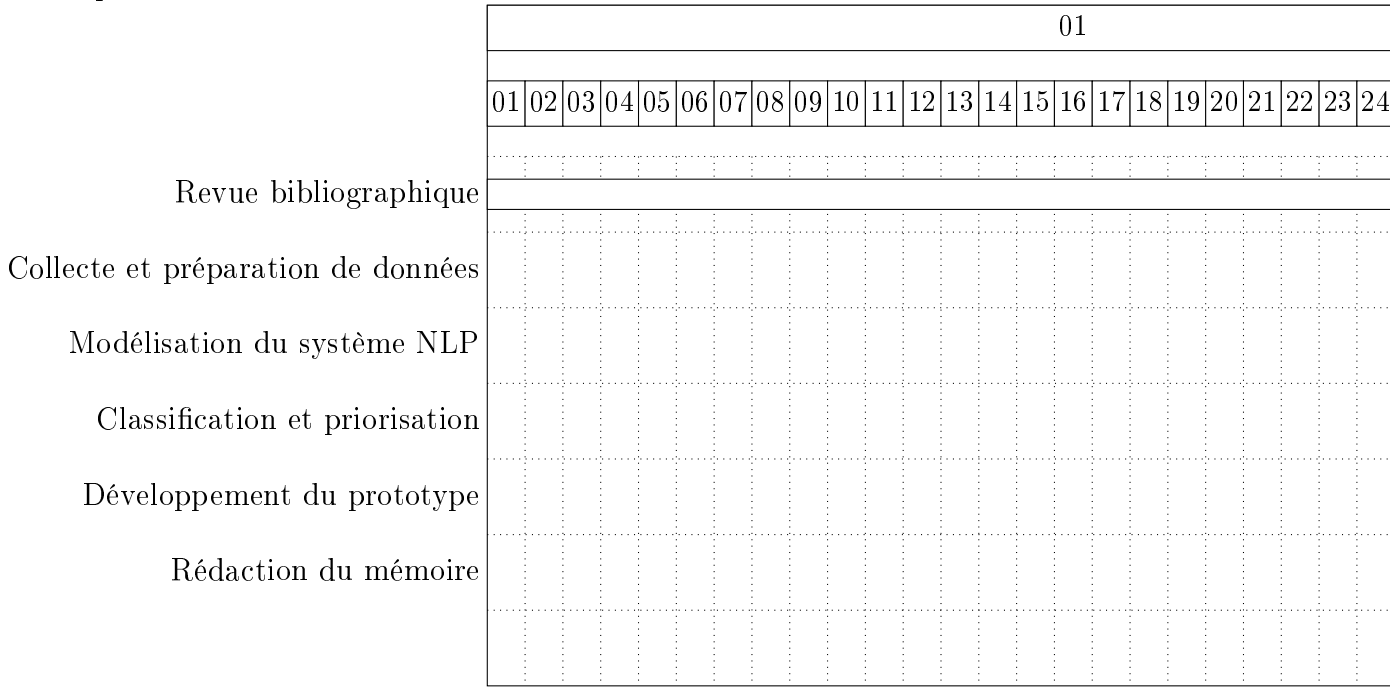

Plan de Travail du Mémoire : Modélisation intelligente et intégration temps réel pour la prédiction et l'équilibrage énergétique durable dans les Smart Grids

Introduction générale

- Contexte énergétique mondial : transition énergétique, intermittence des énergies renouvelables, besoins d'équilibrage.
- Présentation des Smart Grids : capteurs, IoT, compteurs intelligents, pilotage actif.
- Problématique : prédiction de la demande/production et équilibrage énergétique en temps réel.
- Objectifs :
  - Développer un modèle prédictif intelligent.
  - Concevoir un système d'équilibrage énergétique temps réel.
  - Intégrer l'approche dans une architecture Smart Grid.
- Démarche méthodologique : analyse, modélisation, développement IA, simulation, validation.
- Organisation du mémoire.

Revue bibliographique

Smart Grids

- Architecture générale, IoT, SCADA, microgrids.
- Flux énergétiques et gestion intelligente.

Prédiction énergétique

- Modèles classiques : ARIMA, SARIMA.
- Modèles Machine Learning : Random Forest, Gradient Boosting.
- Modèles Deep Learning : LSTM, GRU, Transformers.

Optimisation et équilibrage énergétique

- Demand Response, gestion de charge, stockage.
- Optimisation multi-objectifs, métaheuristiques (PSO, GA).
- Reinforcement Learning pour l'équilibrage.

Outils et plateformes Smart Grid

- OpenDSS, GridLAB-D, TensorFlow, Python, MQTT/Kafka.

Modélisation du système Smart Grid

- Description du réseau étudié (microgrid, réseau urbain, données publiques).
- Modélisation des flux : production, stockage, consommation.
- Modélisation mathématique des contraintes énergétiques.
- Architecture fonctionnelle : acquisition, traitement, IA, décision.

Préparation et analyse des données

- Sources des données : compteurs, météo, bases publiques.
- Prétraitements : nettoyage, interpolation, normalisation.
- Feature engineering : irradiance, température, saisonnalité.
- Analyse exploratoire : visualisation, corrélations.

Modèles de prédiction énergétique

- Construction des modèles : ARIMA, LSTM, Transformers.
- Choix des fenêtres temporelles et hyper-paramètres.
- Évaluation : RMSE, MAE, MAPE.
- Sélection du meilleur modèle.

Modélisation et optimisation de l'équilibrage énergétique

- Détection des déséquilibres.
- Modèle d'ajustement : stockage, DR, redistribution.
- Algorithmes utilisés : heuristiques, PSO, RL.
- Simulation sous OpenDSS / GridLAB-D.

Intégration temps réel

- Cahier des charges du système temps réel.
- Architecture technique : MQTT/Kafka, API, dashboard.
- Déploiement du modèle IA : Docker, microservices.
- Évaluation des performances temps réel.

Résultats et discussion

- Résultats de la prédiction.
- Résultats de l'équilibrage.
- Performance globale du système.
- Limites et interprétation critique.

Conclusion générale et perspectives

- Bilan des apports scientifiques du mémoire.
- Améliorations possibles : IA embarquée, optimisation avancée, Smart Cities.

Annexes

— Codes sources.
— Tableaux et figures supplémentaires.
— Schémas techniques.

Introduction Générale

La transition énergétique mondiale entraîne une évolution profonde des systèmes électriques traditionnels vers des réseaux intelligents, ou *Smart Grids*. Ces réseaux de nouvelle génération intègrent des technologies avancées de communication, d'automatisation et d'intelligence artificielle afin d'améliorer l'efficacité, la flexibilité et la durabilité énergétique. Dans un contexte marqué par l'essor des énergies renouvelables, l'augmentation de la consommation et la nécessité d'un contrôle temps réel, la modélisation intelligente constitue un enjeu majeur.

Les Smart Grids se caractérisent par une forte dynamique : variabilité des sources renouvelables, comportements stochastiques des charges, fluctuations rapides de la demande. Dans ce cadre, la prédiction énergétique et l'équilibrage en temps réel jouent un rôle essentiel pour garantir la stabilité du réseau. Les solutions classiques de contrôle atteignent aujourd'hui leurs limites, d'où l'intérêt des approches basées sur l'apprentissage automatique et les modèles d'estimation avancés.

Ce mémoire s'inscrit dans cette problématique et a pour objectif de proposer une approche intelligente combinant apprentissage automatique, modélisation prédictive et intégration temps réel pour l'optimisation énergétique dans les Smart Grids. L'étude explorera la construction d'un système capable de prédire la consommation et la production, de détecter les déséquilibres et de recommander des actions de régulation assurant une utilisation durable des ressources énergétiques.

Ce travail comprend :
— une revue des concepts de Smart Grids, d'énergie durable et des techniques d'IA ;
— une modélisation mathématique et systémique du réseau intelligent ;
— l'intégration temps réel d'un système prédictif basé sur le Machine Learning ;
— l'étude de schémas d'équilibrage énergétique en environnement dynamique ;
— la validation expérimentale sur un jeu de données simulé.

Ce mémoire contribue ainsi au développement d'outils d'aide à la décision pour une gestion intelligente, flexible et durable de l'énergie.

Revue Bibliographique

Smart Grids

Les Smart Grids représentent une évolution majeure du système électrique en intégrant des technologies numériques, des capteurs, des compteurs intelligents et des systèmes de communication. Leur rôle principal est de surveiller, contrôler et optimiser les flux d'énergie en temps réel.

Production d'énergie durable

L'intégration des sources solaire et éolienne constitue un défi majeur en raison de leur variabilité. Les approches de prédiction basées sur des modèles statistiques et des techniques d'apprentissage profond (LSTM, Transformers) permettent de réduire l'incertitude.

Prédiction énergétique

Les méthodes de prédiction incluent :
— ARIMA et modèles statistiques ;
— Réseaux neuronaux (ANN) ;
— Réseaux récurrents LSTM et GRU ;
— Modèles hybrides ML + optimisation ;
— Algorithmes de renforcement (RL) pour la gestion temps réel.

Équilibrage de charge dans les Smart Grids

Les stratégies d'équilibrage visent à égaliser la production et la consommation :
— gestion de la demande (Demand Response) ;
— stockage énergétique (batteries) ;
— optimisation multi-agent ;
— contrôle prédictif (MPC).

Intégration temps réel

Elle est assurée via :
— IoT et capteurs intelligents ;
— protocoles de communication (MQTT, OPC-UA) ;
— plateformes Big Data (Kafka, Spark Streaming).

Modélisation du Smart Grid

Modèle énergétique

On considère la relation d'équilibrage :

$$P_{\text{prod}}(t) + P_{\text{stock}}(t) = P_{\text{conso}}(t) + P_{\text{pertes}}(t)$$

Modèle prédictif

Soit $X(t)$ un vecteur contenant :

$$X(t) = \{P_{\text{conso}}(t), P_{\text{prod}}(t), T(t), H(t), V(t)\}$$

Le modèle d'apprentissage cherche :

$$\hat{P}_{\text{conso}}(t+1) = f(X(t), X(t-1), \dots)$$

Décision d'équilibrage

On minimise :

$$\min_{u(t)} \ \alpha \cdot \|P_{\text{prod}}(t) + u(t) - \hat{P}_{\text{conso}}(t)\|^2$$

sous contraintes :

$$u_{\min} \leq u(t) \leq u_{\max}$$

où $u(t)$ représente une action : stockage, effacement, redistribution.

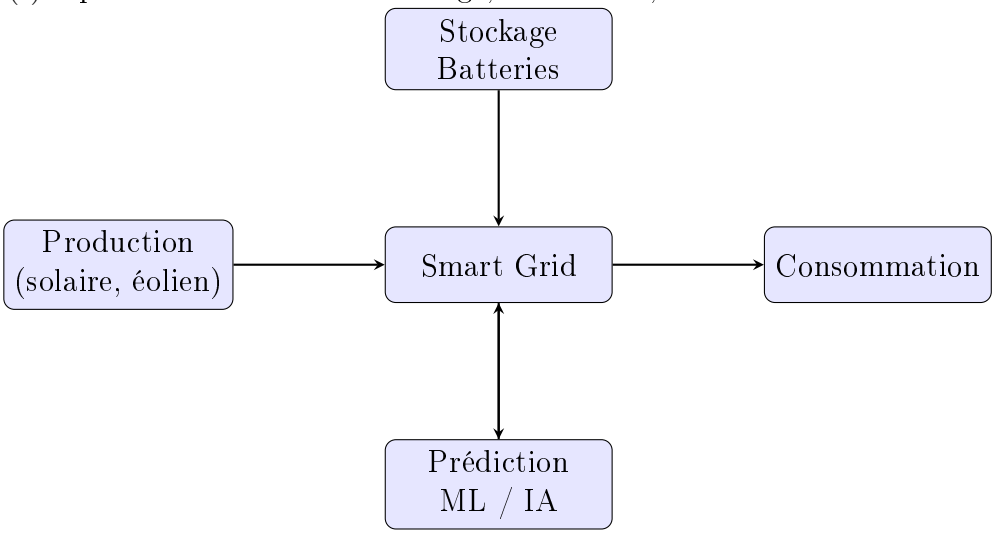

Modèle Mathématique d'Équilibrage

Prédiction énergétique

$$\hat{y}(t+1) = f_\theta(X(t), X(t-1), \dots)$$

Équilibrage optimal

$$\min_{u(t)} J = \sum_t \|P_{\text{prod}}(t) + u(t) - \hat{P}_{\text{conso}}(t)\|^2$$

Sous contraintes :

$$u(t) = u_{\text{stock}}(t) + u_{\text{dr}}(t)$$

$$u_{\min} \leq u(t) \leq u_{\max}$$

$$SOC_{\min} \leq SOC(t+1) = SOC(t) + \eta u_{\text{stock}}(t) \leq SOC_{\max}$$

Plan de travail : Analyse des corrélations entre les variables de décision dans un problème d'optimisation.

Introduction Générale

La gestion de portefeuille financier constitue l'un des domaines les plus étudiés en optimisation mathématique, notamment depuis les travaux fondateurs de Markowitz (1952). Au cœur de ce problème se trouve une idée essentielle : la performance d'un portefeuille ne dépend pas uniquement du rendement attendu des actifs, mais également des corrélations entre ces actifs. Ces interdépendances influencent fortement le risque global, d'où la nécessité de les analyser rigoureusement.

Dans un contexte où les marchés financiers deviennent de plus en plus volatils et complexes, la compréhension des relations entre variables de décision — généralement les pondérations des actifs — est cruciale. L'étude des corrélations permet de mieux structurer les portefeuilles, de réduire la variance non systématique et d'optimiser la diversification.

Ce mémoire s'inscrit dans cette perspective et vise à analyser l'impact des corrélations entre les variables de décision sur l'efficacité des solutions obtenues par différents modèles d'optimisation (Markowitz classique, modèles robustes, optimisation sous contraintes). L'objectif est de mettre en évidence :

— comment les corrélations influencent la structure optimale du portefeuille ;
— dans quelle mesure la matrice de covariance affecte la frontière efficiente ;
— l'effet des corrélations extrêmes (positives ou négatives) ;
— l'évolution des solutions lorsque les dépendances changent dans le temps.

L'étude présente à la fois un cadre théorique, une modélisation mathématique précise et une analyse expérimentale fondée sur des données financières simulées ou réelles.

Revue Bibliographique

Théorie du portefeuille de Markowitz

La théorie moderne du portefeuille repose sur deux quantités : le rendement espéré et le risque, mesuré par la variance. La matrice de covariance des actifs joue un rôle fondamental. Une faible corrélation permet de réduire le risque global grâce à la diversification.

Mesures de corrélation

Les corrélations peuvent être mesurées par :

— corrélation linéaire de Pearson ;
— corrélation de Spearman ;
— corrélation dynamique (DCC-GARCH) ;
— corrélations robustes (typiques en présence de données bruitées ou heavy-tailed).

Optimisation du portefeuille

Les principales approches sont :
— optimisation moyenne-variance ;
— modèles de portfolios robustes ;
— optimisation conique et contraintes normées ;
— approches bayésiennes de la covariance.

Corrélations et diversification

Plus la corrélation entre deux actifs est faible, plus la combinaison réduit le risque. Les corrélations positives renforcent la volatilité. Les corrélations négatives renforcent la diversification.

Applications en data science

Les méthodes utilisées incluent :
— ACP (analyse en composantes principales) pour réduire la dimension de la covariance ;
— clustering financier (K-means, Spectral Clustering) ;
— réseaux de corrélations (Graph Theory) ;
— techniques de visualisation : heatmaps, graphes réseau, hierarchical clustering.

Modélisation Mathématique

Variables de décision

Soit un portefeuille composé de n actifs. Les variables de décision sont :

$$w = (w_1, w_2, \ldots, w_n)$$

avec :

$$\sum_{i=1}^{n} w_i = 1, \quad w_i \geq 0.$$

Rendement espéré

$$\mu_p = \sum_{i=1}^{n} w_i \mu_i$$

Risque du portefeuille

$$\sigma_p^2 = w^T \Sigma w$$

où Σ est la matrice de covariance :

$$\Sigma_{ij} = \sigma_i \sigma_j \rho_{ij}.$$

Modèle d'optimisation

$$\min_{w} \quad w^T \Sigma w$$

sous contraintes :

$$\sum w_i = 1, \quad w_i \geq 0.$$

Impact des corrélations

Une modification de ρ_{ij} modifie l'optimisation :

$$\frac{\partial \sigma_p^2}{\partial \rho_{ij}} = 2 w_i w_j \sigma_i \sigma_j.$$

Cette dérivée mesure l'impact direct d'un changement de corrélation sur le risque du portefeuille.

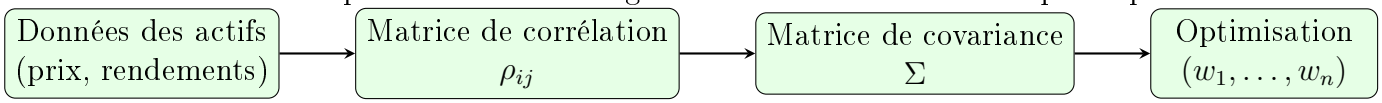

Modèles Avancés

Optimisation robuste

On considère l'incertitude sur la matrice de covariance :

$$\Sigma \in \{\Sigma_0 + \Delta : \|\Delta\| \leq \epsilon\}$$

Le modèle robuste devient :

$$\min_{w} \max_{\|\Delta\| \leq \epsilon} w^T (\Sigma_0 + \Delta) w$$

Analyse spectrale des corrélations

On diagonalise la matrice :

$$\Sigma = Q \Lambda Q^T$$

Les poids w les plus sensibles sont alignés avec les plus grandes valeurs propres :

$$\text{sphère de risque dominée par } \lambda_{\max}.$$

Modèles Avancés

Optimisation robuste

On considère l'incertitude sur la matrice de covariance :

$$\Sigma \in \{\Sigma_0 + \Delta : \|\Delta\| \leq \epsilon\}$$

Le modèle robuste devient :

$$\min_{w} \max_{\|\Delta\| \leq \epsilon} w^T (\Sigma_0 + \Delta) w$$

Analyse spectrale des corrélations

On diagonalise la matrice :

$$\Sigma = Q\Lambda Q^T$$

Les poids w les plus sensibles sont alignés avec les plus grandes valeurs propres :

$$\text{sphère de risque dominée par } \lambda_{\max}.$$